2-2 인공지능의 편향과 딜레마

학습 목표 • 인공지능 편향의 문제점을 탐색할 수 있다.
• 윤리적 딜레마 상황을 인공지능 윤리 관점에서 분석할 수 있다.

핵심 요소 인공지능의 편향, 윤리적 딜레마

01 인공지능의 윤리적 문제는 왜 중요할까?

인공지능이 사회 전반에 도입되면서 윤리적 문제가 많아졌기 때문이다.

인공지능 시스템이 윤리적 판단을 내릴 수 있는지는 여전히 논란거리이다. 이는 독립적으로 생각하고, 감정을 느끼며, 윤리적 가치를 이해하는 능력이 있는 인간과 달리, 인공지능은 기계학습 알고리즘과 프로그래밍에 의해 작동되는 시스템이기 때문이다.

1 인공지능의 편향

인공지능은 중립적이라 생각하지만, 인간이 만든 데이터와 알고리즘에 기반해 학습하기 때문에 **편향성**을 가질 수 있다.

학습 데이터 편향

- 알고리즘은 데이터를 처리하고 패턴을 학습하는 방법이다.
- 알고리즘이 특정 패턴이나 속성에 더 큰 가중치를 부여한다면, 그 결과는 특정 방향으로 편향될 수 있다.
- 알고리즘이 어떤 패턴을 우선시할지가 결정되면 이로 인해 편향될 수 있다.

알고리즘 편향

- 과거의 경험, 사실, 사람들의 행동 등을 반영하여 데이터에 편향이나 불균형이 있을 수 있다.
- 특정 인종, 성별, 연령대의 데이터가 많거나 적다면, 학습된 모델 역시 그 편향을 반영하게 될 수 있다.
- 불균형한 데이터로 학습된 인공지능은 잘못된 판단을 내릴 수 있다.

위 내용을 기본으로 인공지능의 편향을 더 깊이 이해하기 위해 [표 Ⅲ-1]에서 인간과 인공지능의 편향을 다양하게 비교 및 분석해 보자.

▾ 표 Ⅲ - 1 인간과 인공지능의 편향

항목	인간의 편향	인공지능의 편향
편향의 근본적 이유	경험, 문화, 교육, 사회적 환경을 통한 학습	학습 데이터와 알고리즘에 기반해 학습
편향의 변경 가능성	시간과 경험에 따라 의견과 인식이 변할 수 있다.	데이터 또는 알고리즘이 변경되지 않는 한 동일한 패턴을 보인다.
인식 및 수정 가능성	자신의 편향을 인식하기 어렵고 자각 및 교육을 통해 수정할 수 있다.	결과가 편향적으로 나오는 현상을 통해 인식할 수 있고, 데이터와 알고리즘 변경으로 수정할 수 있다.
편향의 영향력	개인이나 집단의 행동, 선택, 판단에 영향을 줄 수 있다.	다양한 프로그램, 서비스, 시스템에 영향을 줄 수 있다.

2 편향에 따른 윤리적 쟁점 사례

인공지능은 이전 데이터와 알고리즘에 기초해 판단을 내리기 때문에 때때로 인간의 윤리적 가치와 맞지 않을 수 있다. 따라서 인공지능 윤리는 그 시스템이 인간 사회의 가치와 얼마나 잘 부합하는지, 그리고 그 결정이 어떠한 윤리적 영향을 미치는지를 생각해 봐야 한다. 인공지능 면접관, 킬러 로봇, 생성형 인공지능의 편향에 따른 **윤리적 쟁점** 사례를 통해 편향에 따른 윤리적 문제점을 살펴보자.

편향에 따른 윤리적 쟁점 사례	편향에 따른 윤리적 문제점
인공지능 면접관 최근 우리나라에서는 코로나 사태로 인공지능 면접관이 부각되었으며, 비대면에 적합하고 경제적이라는 이유로 기업에서 도입하고 있다. 인공지능 면접관은 지원자의 얼굴 표정, 음성 분석 등을 통해 지원자를 평가한다고 알려지고 있지만 뚜렷한 평가 방법은 알기 힘들다. 정답과는 다른 대답을 해도 표정이나 목소리만으로 높은 점수를 줄 수 있다. 이러한 얼굴의 표정과 같은 외적인 모습으로 지원자의 내적 상태를 파악하거나 업무 역량을 평가하기는 어렵다는 문제점이 제기되었다.	특정 성별, 인종, 연령대, 지역, 교육, 외모, 목소리 등의 **외적인 속성으로 불리하게 평가**될 수 있다. 이로 인해 차별과 불평등이 심화될 수 있으며 잠재적인 인재를 놓칠 위험이 있다.
킬러 로봇 킬러 로봇은 군대의 자율 무기로 전쟁에서 사람의 개입 없이 자율적으로 공격하고 방어할 수 있는 인공지능 무기 시스템을 의미한다. 최근 국가의 무기 시스템을 로봇이나 드론이 맡아서 수행하는 방식으로 바뀌고 있는데, 이는 아군의 인명 피해를 최소화하고 정밀하게 적을 파괴할 수 있다. 하지만 오용될 가능성이 있고, 사람을 위협하는 존재가 될 수 있다는 경고의 목소리가 크다.	로봇이 타깃으로 삼는 **대상을 잘못 학습**하면 특정 집단에 대한 무차별적 공격이나 과도한 공격성을 보일 수 있다. 따라서 잘못된 목표를 공격하거나 역으로 위험에 빠질 수 있다.
생성형 인공지능 생성형 인공지능은 텍스트, 이미지, 오디오, 비디오와 같은 다양한 형태의 콘텐츠를 생성할 수 있는 인공지능의 한 유형이다. 딥페이크라는 딥러닝 기술은 영상 편집 기술과 얼굴 합성 기술을 결합하여 가짜 음성, 영상, 이미지 등을 생성하는 방법이다. 학습 데이터의 양을 증가시키는 데 도움이 될 수 있으며 영화나 광고에서는 사망한 유명 인사를 스크린에 되살리거나 흥미로운 장면을 연출하는 데 딥페이크 기술을 적용하고 있다. 특히, 우리나라에서는 3·1절을 맞아 일제 강점기 당시 나라를 위해 헌신한 독립운동가의 생전 모습을 생동감 있게 복원하기도 하였다. 하지만 악의적인 가짜 뉴스 및 영상이나 음성 생성으로 혼란과 불안에 빠지는 사회적 문제를 일으킬 수 있으므로 관련 법률과 기술적 대응책이 필요하다. 복원된 독립운동가들	생성된 정보나 콘텐츠에 **특정 집단의 가치관이나 이익이 반영**되게 만들어질 수 있다. 이를 이용하여 가짜 뉴스, 언론 조작, 누군가의 얼굴 합성 또는 수정, 음란물 생성 등 악의적인 목적으로 악용되고 있으며, 개인 정보 유출로 사생활 침해와 개인의 안전을 위협하기도 한다.

02 윤리적 딜레마는 왜 중요할까?

인공지능은 올바른 선택을 하고 그 선택에 책임을 져야 하기 때문이다.

1 윤리적 딜레마

윤리적 딜레마는 어떤 상황에서 한 가지 결정을 내려야 하는데, 그 결정이 도덕적으로 복잡하거나 모순적인 결과를 초래할 수 있는 상황을 말한다.

트롤리 딜레마 TIP

트롤리 문제는 필리파 풋이 먼저 제시하였고 이를 주디스 자비스 톰슨 등이 체계적으로 분석하였다.
이는 윤리학의 사고 실험(상상력을 동원하는 실험)의 하나로 "무엇이 옳은 반응인가?"를 따지는 것이며 "사람들은 보통 어떻게 반응하는가?"를 살펴보는 것이라 할 수 있다.

(1) 트롤리 딜레마

자율주행 자동차가 가시화되면서 브레이크 고장과 같은 위급한 상황에서 두 가지 선택지가 있을 때 개인이나 조직은 어떤 판단을 해야 할지에 대한 문제가 논의되고 있다. 다음 트롤리 딜레마(trolley dilemma) 사례에서 나는 어떻게 행동하는 것이 옳을지 생각해 보자.

사례 1

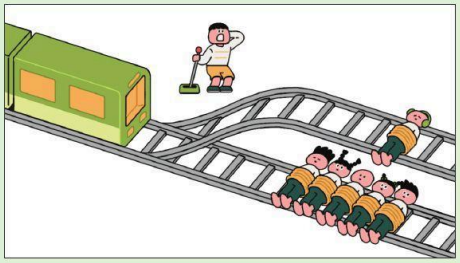

트롤리(작은 전차)가 선로를 따라 달려오고 있고, 선로에는 5명이 있다. 또 다른 선로에는 1명이 있고 나는 선로 밖에 서 있다.
5명을 구하기 위해서는 선로 전환기를 당기면 되지만 그렇게 되면 다른 선로에 있는 1명이 죽게 된다.

윤리적 딜레마 문제

1명을 구하기 위해 가만히 있어야 할까? 5명을 구하기 위해 선로 전환기를 당겨야 할까? 선로 전환기를 당기는 행위는 도덕적으로 허용할 수 있는가?

[사례1]의 해석

5명을 살리기 위해 1명이 희생되어야 하는가의 문제이다.

사례 2

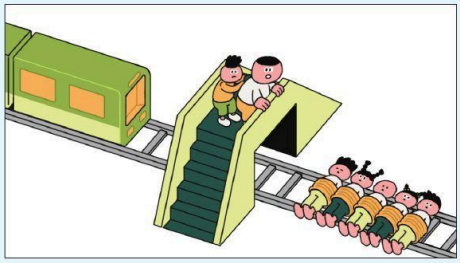

트롤리는 선로를 따라 달려오고 있고, 선로에는 5명이 있다. 나는 선로 위 육교 위에 서 있고, 내 옆에는 트롤리를 멈추게 할 만한 몸무게의 1명이 서 있다.
5명을 구하는 유일한 방법은 옆에 서 있는 사람을 선로 위로 밀쳐서 그 무게로 트롤리를 멈추게 하는 것이다.

윤리적 딜레마 문제

5명을 구하기 위해 1명을 밀어야 할까? 트롤리는 멈추지만 그 사람은 죽게 된다. 이 행위는 도덕적으로 허용할 수 있는가?

[사례2]의 해석

[사례1]과 동일한 결과이지만 육교 위 1명을 희생하는 것에 초점을 맞추어 생각하는 문제이다.

(2) 자율주행 자동차의 딜레마

자율주행 자동차의 딜레마는 트롤리 문제와 매우 유사하다. 다른 점이라면 트롤리 문제는 딜레마의 상황에서 선택하는 주체가 사람이지만, 자율주행 자동차는 인공지능이 선택한다는 것이다. 트롤리 문제와 같은 상황이 발생했을 때 인공지능은 어떻게 행동하는 것이 옳을지 생각해 보자.

사례 3

자율주행 자동차가 도로에서 빠르게 달리고 있다. 갑자기 브레이크가 고장났는데 앞에 노인과 어린아이가 보인다. 자동차는 충돌을 피할 수 없는 상황에 처했다.

윤리적 딜레마 문제

자율주행 자동차는 누구를 피해야 할까? 노인을 피하고 어린아이를 치는 것이 옳을까, 아니면 그 반대일까?

[사례3]의 해석

- **나이 기준:** '어린아이가 중요하다', '노인이 중요하다', '나이에 상관없이 모든 생명이 동일하게 중요하다'라는 세 가지 주장이 나올 수 있다.
- **사회적 가치 기준:** '젊은 사람이 더 많은 사회적 가치를 가지고 있다'라는 주장이 나올 수 있지만 이는 논의하기 불편한 주제이다.
- **무작위 선택:** '모든 생명이 동등하게 중요하다'라는 원칙이 있지만, '운에 의해 결정된다'라는 불편함이 있다.

자율주행 자동차 딜레마 연구 TIP

2008년 미국 매사추세츠공대(MIT)에서 세계의 230만 명을 대상으로 '자율주행 자동차는 누구부터 살펴야 할까?'를 주제로 연구를 진행했으며 그 결과는 다음과 같다.

1위 : 유모차 끄는 사람
2위 : 소녀
3위 : 소년
4위 : 임신 여성
5위 : 남성 의사
6위 : 여성 의사
7위 : 여성 운동선수
8위 : 여성 경영인
9위 : 남성 운동선수
10위 : 남성 경영인
11위 : 일반 성인
12위 : 비만 여성
13위 : 비만 남성
14위 : 노숙인
15위 : 노년 남성
16위 : 노년 여성
17위 : 개
18위 : 범죄자
19위 : 고양이

참고로 북미 · 유럽에서는 '어린아이가 우선'인 반면 동방국가에서는 '노인이 우선'으로 나왔다.

AI와 함께 지식 키우기

트롤리 딜레마 문제의 설문 결과

마크 하우저(Marc D. Hauser)가 2007년에 5000명을 대상으로 트롤리 딜레마에 관해 실시한 온라인 설문 조사에 따르면 다음과 같은 결과가 나왔다.

- [사례1]은 89%가 찬성하였고, [사례2]는 11%만이 찬성하였다. 이는 성별, 교육, 문화적 차이와 상관없이 공통적이었다.
- [사례1]과 [사례2]의 '태도가 변하는 것에 대해 죽음이 얼마나 불가피한 것인가'와 '타인의 죽음에 내가 얼마나 직접으로 개입하느냐'가 영향을 끼쳤다.
- [사례1]은 6명 모두 철길 위에 있고 5명 또는 1명의 죽음이 불가피하다. 선로 전환기를 당긴다는 행위가 직접적으로 사람을 죽인다는 부분이 [사례2]에 비해 덜하다.
  따라서 [사례2]보다 [사례1]에 더 많은 사람들이 찬성을 했다.

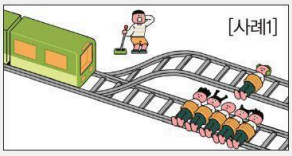

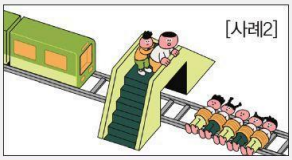

2 윤리적 딜레마를 해결하기 위해 고려할 점

사람의 결정과 판단은 해당 사회의 문화, 가치관, 윤리에 기반하며, 때때로 윤리적 딜레마를 야기한다. 인공지능이 사회 문제 해결에 점점 더 활용되면서 그 결정과 판단이 윤리적으로 문제가 없는지 중요한 이슈로 등장했다. 따라서 윤리적 딜레마 문제를 통해 먼저 인공지능의 윤리적 기준을 파악해야 한다. 이를 바탕으로 다음에 제시한 질문 유형의 복잡한 윤리 문제를 논의하고 이해하는 것이 중요하다.

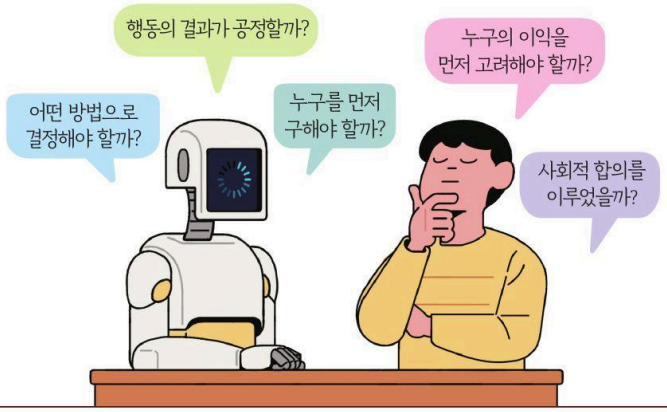

스스로 해결하기

분석 표현

다음 글을 읽고 인공지능 편향의 문제를 분석해 보자.

인공지능은 어쩌다 편견과 혐오를 배웠을까? 기업에서 출시한 '챗봇'은 주요한 인공지능 윤리 문제를 야기했고, 특히 특정 계층에 대한 편향적이고 혐오적인 발언이 사회적 논란을 일으켰다. 인공지능의 외모, 말, 행동 등이 인간과 유사하면, 인간은 인공지능에 감정을 이입하고 인공지능을 의인화한다. 따라서 사용자인 인간이 편향된 인공지능 발언을 무의식적으로 수용할 수 있으며, 어린이와 청소년들은 더 쉽게 이런 상황에 노출되어 심각한 영향을 받을 수 있다.

과거 구글과 마이크로소프트에서도 편향된 데이터 학습으로 인한 문제가 발생했는데, 이는 인공지능이 편향된 데이터를 학습하면 그 결과도 편향될 수 있다는 것을 보여 준다. 따라서 인공지능 학습 데이터는 신중하게 검토하고 정제하는 과정이 필요하다.

1 **편향이 사회적인 문제가 되는 이유를 써 보자.** _____

2 **인공지능이 혐오적이거나 편향된 발언을 하는 이유는 무엇인지 써 보자.** _____

성취도 평가 인공지능 편향의 문제점을 설명할 수 있는가? 예 □ 아니요 □

분석 토론

함께 해결하기

주어진 딜레마 상황에서 윤리적 문제를 찾아 토론해 보자.

1 다음과 같은 딜레마 상황에서 윤리적 문제를 이해하고 모둠별로 의견을 나누어 보자.

자율주행 자동차가 도로를 달리고 있다. 갑자기 차량 앞으로 신호를 위반한 보행자 한 명이 차도로 뛰어든다. 자율주행 자동차는 브레이크를 밟아도 충돌을 피할 수 없는 속도로 달리고 있다. 보행자를 피하면 차가 가로수에 부딪혀 운전자가 크게 다칠 수 있고, 피하지 않으면 보행자가 크게 다칠 수 있다. 이때 자율주행 자동차는 보행자를 피해야 할까? 아니면 피하지 않아야 할까?

딜레마 상황 자율주행 자동차를 개발하는 회사는 운전자와 보행자 중 누구의 안전을 먼저 생각해야 하는가?

운전자의 안전이 중요하다. — **윤리적 문제** — **보행자**의 안전이 중요하다.

2 각각의 주장에 대한 근거 자료를 수집하여 작성하고 토론해 보자.

주장	근거
운전자의 안전이 중요하다.	예 자율주행 자동차는 기본적으로 운전자를 보호하는 데 초점을 맞춰야 한다.
보행자의 안전이 중요하다.	예 보행자는 자율주행 자동차에 비해 더 취약한 상태에 있으므로 그들의 안전을 더 중요시해야 한다.

3 토론을 한 후 우리 모둠의 결론을 발표해 보자.

성취도 평가 윤리적 딜레마 상황을 인공지능 윤리 관점에서 분석할 수 있는가? 예 □ 아니요 □

주요 개념 정리하기

- 인공지능은 인간이 만든 데이터와 알고리즘에 기반해 학습하기 때문에 편향성을 가질 수 있다.
- 윤리적 딜레마 상황은 인공지능과 관련된 복잡한 윤리적 문제를 논의하고 이해하는 데 유용하다.